TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO THỰC HÀNH BUỔI 8

WORKSHOP XÂY DỰNG MODULE CỐT LÕI (SPRINT 1)

HỌC PHẦN: CHUYÊN ĐỀ TỐT NGHIỆP 1 (71ITGR40203)

Chuyên ngành: Phân tích Dữ liệu (Data Analytics – Track DA)

Đề tài:

KIỂM TRA VÀ LÀM SẠCH DỮ LIỆU KHÁCH HÀNG (SMART CRM – MEKONG MOBILE – LUỒNG L7)

Sinh viên thực hiện	:	**Hồ Lê Trung Bảo**
Mã số sinh viên	:	**2374802010030**
Lớp sinh hoạt	:	**K29 - 71ITGR40203**
Giảng viên hướng dẫn	:	**TS. Nguyễn Trí Hải**
Repository GitHub	:	https://github.com/HoLeTrungBao/smartcrm-2374802010030-customer-data-quality

TP. HỒ CHÍ MINH – NĂM 2026

PHẦN 1. TIẾP NHẬN & KHẮC PHỤC PHẢN HỒI BÀI TẬP 1

> **Kết quả đánh giá BT1 từ Giảng viên hướng dẫn:** Điểm **7.0/10** (Đầy đủ: 9.0 · Kỹ thuật: 5.25 · Nhất quán: 6.5 · Trình bày: 8.5).
> *Điểm tốt:* Kiến trúc 5 tầng phân định rõ trách nhiệm; 3 câu lập luận NFR đúng khuôn; grain bảng Fact phát biểu chuẩn; ánh xạ wireframe rõ ràng.
> *Gợi ý then chốt cho BT2:* Chốt một bộ tên cột duy nhất cho Fact và Dim, sửa lại sơ đồ, từ điển dữ liệu và script ETL cho khớp trước khi viết mã.

1.1. Bảng tổng hợp các điểm điều chỉnh theo phản hồi của Giảng viên

Ý kiến nhận xét của GV	Giải pháp khắc phục cụ thể	Thành phần tài liệu / mã nguồn	Trạng thái
1. Thiếu bảng thuật ngữ & ma trận truy vết gộp	Bổ sung Bảng thuật ngữ chuyên ngành chuẩn vào Mục 1.4 SRS; Thêm Mục 6 Bảng ma trận truy vết gộp (FR ↔ US ↔ UC ↔ MoSCoW ↔ Module code ↔ Wireframe).	`docs/srs.md` (Mục 1.4, Mục 6) `README.md`	**ĐÃ KHẮC PHỤC**
2. Sơ đồ Use Case thiếu chú thích & thiếu Actor QTV	Bổ sung Actor Quản trị viên hệ thống (System Administrator); thêm bảng chú thích ký hiệu (Legend) giải thích rõ Actor, Use Case, Include/Extend.	`docs/usecase.drawio` `docs/srs.md` (Mục 2)	**ĐÃ KHẮC PHỤC**
3. Sơ đồ Star Schema lệch từ điển dữ liệu 4.4	Chốt bộ tên cột duy nhất: `customer_id`, `ho_ten_raw/clean`, `so_dien_thoai_raw/clean`, `is_valid`, `error_count`. Loại bỏ các tên cũ lệch pha.	`docs/thay-doi-thiet-ke.md` `sql/010_dim.sql`, `sql/020_fact.sql`	**ĐÃ KHẮC PHỤC**
4. NFR05 che PII chưa có ngưỡng số đo được	Định lượng hóa cụ thể: 100% màn hình hiển thị PII cho vai trò không có quyền đều bị che mặt nạ (0912***678 và a***@domain); tỷ lệ rò rỉ là 0,00%.	`docs/srs.md` (Mục 4 NFR05) `src/transform/rules.py`	**ĐÃ KHẮC PHỤC**
5. Wireframe chưa ghi mỗi màn hình phục vụ UC nào	Ánh xạ rõ: Màn hình 1 phục vụ UC07; Màn hình 2 phục vụ UC01, UC02, UC05; Màn hình 3 phục vụ UC04, UC06.	`docs/srs.md` (Mục 6) `README.md`	**ĐÃ KHẮC PHỤC**

1.2. Nhật ký thay đổi thiết kế (Design Change Log)

Nhóm đã lập tài liệu `docs/thay-doi-thiet-ke.md` theo đúng format chuẩn 3 dòng: **Thay đổi gì · Vì sao · Ảnh hưởng tới thành phần nào**. Trong đó bổ sung 3 bài học kỹ thuật quan trọng rút ra từ mẫu tham chiếu `mekong-da-pipeline`:

- **Mã lô xác định theo phạm vi dữ liệu (Idempotence):** Sinh mã `lo-toan-bo` thay vì dùng dấu thời gian ngẫu nhiên để tránh phình to bảng staging và reject khi chạy lại nhiều lần (giải quyết triệt để lỗi BUG-01 từ kinh nghiệm tham chiếu).
- **Bổ sung bảng `reject_rows` và `quality_measures`:** Mọi dòng lỗi đều được lưu giữ nguyên vẹn kèm lý do diễn giải cho con người đọc hiểu, không nuốt lỗi âm thầm.
- **Xử lý an toàn giá trị rỗng với hàm thuần `_rong()`:** Nhận diện đầy đủ cả `None`, chuỗi rỗng, `NaN` của Numpy và `pd.NA` của Pandas, tránh lỗi dừng tiến trình.

PHẦN 2. KIẾN TRÚC VÀ CẤU TRÚC MÃ NGUỒN 4 PHA (TRACK DA)

Thực hiện đúng yêu cầu của Buổi 7 & Buổi 8 và tham chiếu từ kiến trúc chuẩn của học phần, mã nguồn được phân rã thành 4 pha rõ rệt với ranh giới trách nhiệm nghiêm ngặt:

2.1. Sơ đồ luồng dữ liệu 4 pha và Bảng phân chia trách nhiệm

Luồng vận hành khép kín của Pipeline:
`customers_raw.csv` → **Extract** → **Transform** → **Quality** → **Load** → **Kho dữ liệu Star Schema**
↓
Bảng `reject_rows` + Báo cáo chất lượng tự động (`reports/*.md`)

Pha xử lý	Thư mục / Tập tin	Trách nhiệm nghiệp vụ & Kỹ thuật	Ranh giới cấm
1. EXTRACT	`src/extract/read_sources.py`	Đọc an toàn 67.037 bản ghi từ `customers_raw.csv`. Ép kiểu chuỗi (dtype=str) để giữ nguyên vẹn số 0 ở đầu số điện thoại.	**CẤM biến đổi dữ liệu**
2. TRANSFORM	`src/transform/rules.py` `src/transform/clean_customers.py`	Tập hợp các HÀM THUẦN (Pure functions): Chuẩn hóa SĐT về 10 số (0xxxxxxxxx), chuẩn hóa họ tên về Title Case, email RFC và đọc ngày; che mặt nạ PII (NFR05); tách luồng `df_sach` và `df_reject`.	**CẤM đọc/ghi CSDL**
3. QUALITY	`src/quality/checks.py`	Đo lường 3 chiều chất lượng (Đầy đủ, Chính xác, Nhất quán) thông qua `dataclass Do`. Mỗi phép đo trả về số dòng kiểm, số đạt, số lỗi và tỷ lệ % cụ thể.	**CẤM chỉ trả True/False**
4. LOAD	`src/load/load_staging.py` `src/load/load_warehouse.py`	Nạp dữ liệu vào bảng Staging, bảng Reject và kho Star Schema (Fact + Dimension). Áp dụng cơ chế Idempotent để chạy lại lần hai không làm nhân đôi số bản ghi.	**CẤM biến đổi dữ liệu**
Entrypoint	`src/pipeline.py`	Điều phối 4 pha bằng MỘT LỆNH; kiểm tra chất lượng TRƯỚC KHI NẠP; tự động ghi nhận báo cáo Markdown và JSON sau mỗi phiên chạy.	**Chạy 1 lệnh**

2.2. Khung DDL Cơ sở dữ liệu kho Star Schema

Toàn bộ cấu trúc bảng được chuẩn hóa thành các tệp tin DDL tại thư mục `sql/`:

- `sql/001_staging.sql`: Bảng `staging_customers` lưu dữ liệu nguồn nguyên trạng theo `batch_id`.
- `sql/002_reject.sql`: Bảng `reject_rows` lưu các dòng không chuẩn hóa được kèm cột `ly_do_loi` và `ma_quy_tac`; Bảng `quality_measures` lưu các chỉ số đo định lượng của từng lô.
- `sql/010_dim.sql`: Các bảng chiều `dim_customer` (lưu song song cả trường thô và trường sạch để truy vết), `dim_quality_rule` (bộ quy tắc chuẩn DQ01–DQ06) và `dim_audit_run` (phiên chạy).
- `sql/020_fact.sql`: Bảng sự kiện `fact_customer_quality_audit` với grain chuẩn: Một quy tắc, một khách hàng, một phiên kiểm định.

PHẦN 3. KẾT QUẢ THỰC NGHIỆM TRÊN TẬP DỮ LIỆU THỰC TẾ

Pipeline đã được thực thi trên toàn bộ tập dữ liệu thực tế `customers_raw.csv` gồm **67.037 bản ghi** của Mekong Mobile bằng một lệnh duy nhất: `python -m src.pipeline`. Thời gian thực thi toàn bộ 4 pha chỉ mất **8,9 giây**.

3.1. Đối soát số lượng bản ghi qua các pha xử lý

Bảng lưu trữ / Đối tượng	Số bản ghi	Tỷ lệ trên tổng	Diễn giải nghiệp vụ & Kỹ thuật
Dữ liệu thô ban đầu (Extract)	**67.037**	100,00%	Nạp toàn vẹn từ tập tin `customers_raw.csv` vào `staging_customers`.
Khách hàng sạch (Transform)	**62.904**	**93,83%**	Dữ liệu đạt chuẩn họ tên, số điện thoại được chuẩn hóa thành công về 10 chữ số.
Dòng từ chối (Reject Rows)	**4.133**	**6,17%**	Bản ghi số điện thoại sai định dạng nghiêm trọng (thiếu số, chứa chữ, không chuẩn hóa được).
Khách hàng nạp vào `dim_customer`	**62.904**	**93,83%**	Nạp thành công vào kho Star Schema (khóa chính tự nhiên `customer_id`).
Sự kiện nạp vào Fact Table	**62.904**	**93,83%**	Ghi nhận đầy đủ trạng thái hợp lệ, cờ trùng lặp và số lỗi vào `fact_customer_quality_audit`.

3.2. Kết quả đo lường 3 chiều chất lượng dữ liệu (Data Quality Checks)

Chiều	Chỉ tiêu kiểm định	Số kiểm	Số đạt	Số lỗi	Tỷ lệ	Ngưỡng
ĐẦY ĐỦ	`customers.customer_id`	67.037	67.037	0	**100,00%**	100,00%
ĐẦY ĐỦ	`customers.ho_ten`	67.037	67.037	0	**100,00%**	98,00%
ĐẦY ĐỦ	`customers.so_dien_thoai`	67.037	62.904	4.133	**93,83%**	98,00%
ĐẦY ĐỦ	`customers.email`	67.037	36.880	30.157	**55,01%**	50,00%
CHÍNH XÁC	`sdt_chuan_hoa_duoc`	62.904	62.904	0	**100,00%**	95,00%
CHÍNH XÁC	`ho_ten_chuan_hoa_duoc`	67.037	62.904	4.133	**93,83%**	98,00%
CHÍNH XÁC	`email_dung_dinh_dang`	36.880	34.604	2.276	**93,83%**	95,00%
CHÍNH XÁC	`ngay_dang_ky_hop_le`	67.037	62.904	4.133	**93,83%**	98,00%
NHẤT QUÁN	`ty_le_sdt_duy_nhat`	62.904	35.781	27.123	**56,88%**	70,00%

3.3. Chi tiết Bảng Reject (Bản ghi từ chối kèm lý do viết cho con người)

Toàn bộ **4.133 bản ghi lỗi** được lưu trữ an toàn trong bảng `reject_rows` với mã quy tắc `DQ02_PHONE`. Cột `ly_do_loi` mô tả rõ ràng: *"Số điện thoại '[giá trị]' không thể chuẩn hóa về 10 chữ số chuẩn"*. Hệ thống không xóa bỏ dữ liệu mà bảo toàn 100% dữ liệu gốc để đối soát thủ công.

PHẦN 4. KIỂM CHỨNG CỐT LÕI (IDEMPOTENCE & TESTING)

4.1. Phép thử "Chạy lại được" (Idempotent - Tiêu chí C5 của BT2)

> **Câu hỏi then chốt của Giảng viên khi chấm:** *"Chạy pipeline hai lần với cùng đầu vào thì số bản ghi trong CSDL thế nào? Lần hai bị nhân đôi nghĩa là chưa đạt."*

Pipeline đã hiện thực cơ chế quản lý theo mã lô `batch_id` kết hợp lệnh `INSERT ... ON CONFLICT(customer_id) DO UPDATE` cho `dim_customer` và xóa theo phiên chạy cho `fact_customer_quality_audit`. Kết quả thực nghiệm kiểm chứng sau 2 lần chạy liên tiếp:

Tên bảng trong Cơ sở dữ liệu	Số bản ghi sau Lần 1	Số bản ghi sau Lần 2	Đánh giá tính Idempotent
`staging_customers`	67.037	67.037	✅ **Khớp 100% (Không nhân đôi)**
`reject_rows`	4.133	4.133	✅ **Khớp 100% (Không nhân đôi)**
`dim_customer`	62.904	62.904	✅ **Khớp 100% (Không nhân đôi)**
`fact_customer_quality_audit`	62.904	62.904	✅ **Khớp 100% (Không nhân đôi)**

4.2. Bộ kiểm thử tự động với Pytest (Tiêu chí C4 của BT2)

Toàn bộ các hàm chuẩn hóa trong `rules.py` và đo lường trong `checks.py` đều là hàm thuần và được kiểm thử độc lập bằng lệnh: `python -m pytest -q`. Kết quả đạt **11/11 tests PASS (100%)**:

Loại test	Tên ca kiểm thử	Mục đích & Dữ liệu kiểm tra	Kết quả
1. Luồng đúng	`test_sdt_luong_dung`	SĐT chuẩn 10 số (`0901234567`), chứa dấu chấm hoặc khoảng trắng chuyển đúng về 10 số.	**PASS (0.01s)**
1. Luồng đúng	`test_ho_ten_luong_dung`	Họ tên viết thường, thừa khoảng trắng (`  nguyễn văn an  `) chuyển về Title Case.	**PASS (0.01s)**
2. Giá trị biên	`test_sdt_gia_tri_bien`	Tiền tố quốc tế có dấu cộng `+84901234567` (12 ký tự) và `84901234567` (11 ký tự) quy về 10 số.	**PASS (0.01s)**
2. Giá trị biên	`test_ho_ten_gia_tri_bien`	Tên chỉ 1 từ (`bảo` → `Bảo`) hoặc chuỗi tiếng Việt có dấu gạch ngang.	**PASS (0.01s)**
3. Dữ liệu sai	`test_sdt_du_lieu_sai`	SĐT thiếu số (8 số), thừa số, chứa chữ cái, rỗng hoặc chuỗi `'nan'` → trả về `None`.	**PASS (0.01s)**
3. Dữ liệu sai	`test_ho_ten_du_lieu_sai`	Họ tên chỉ toàn khoảng trắng hoặc chuỗi `'None'` → trả về `None`.	**PASS (0.01s)**
Bảo mật PII	`test_che_mat_na_pii`	Kiểm tra hàm che PII (NFR05): SĐT thành `0901***567` và email thành `t***@gmail.com`.	**PASS (0.01s)**
Chất lượng	`test_xu_ly_lam_sach_va_reject`	Kiểm tra phân tách chính xác 3 dòng sạch và 3 dòng reject trên tập fixture mẫu.	**PASS (0.02s)**
Chất lượng	`test_do_tat_ca_chat_luong`	Kiểm tra tính toán số đo 3 chiều trả về đối tượng `Do` có tỷ lệ và số lỗi hợp lệ.	**PASS (0.02s)**

PHẦN 5. QUẢN LÝ PHIÊN BẢN & KÊ KHAI SỬ DỤNG AI

5.1. Lịch sử Commit và Quản lý phiên bản Git

Dự án tuân thủ nghiêm ngặt quy ước **Conventional Commits** theo chuẩn Buổi 7. Các commit phản ánh từng đơn vị công việc hoàn chỉnh:

- `94c9c9d` – `feat(core): implement core ETL pipeline, quality checks, idempotent load and design updates for BT2` (Thực hiện trọn vẹn Buổi 8).
- `634c90a` – `docs: finalize BT1 official report PDF and synchronize technical diagrams` (Hoàn tất nộp BT1).
- `f47a9c0` – `docs: complete BT1 analysis and design specification for track DA` (Đặc tả thiết kế ban đầu).
- `8b3533c` – `docs: complete Buoi 4 requirements` (Khởi tạo yêu cầu môn học).

Toàn bộ mã nguồn đã được đồng bộ trực tiếp lên GitHub:
`https://github.com/HoLeTrungBao/smartcrm-2374802010030-customer-data-quality`

5.2. Bảng kê khai sử dụng công cụ AI (AI Disclosure)

Công cụ AI	Mục đích & Nội dung hỗ trợ	Phương pháp kiểm chứng của Sinh viên
Gemini / Antigravity	Hỗ trợ rà soát cấu trúc thư mục 3 lớp chuẩn DA theo slide bài giảng Buổi 7; gợi ý mẫu hàm đo 3 chiều bằng dataclass.	Sinh viên tự tay đối chiếu với sơ đồ kiến trúc 5 tầng đã nộp ở BT1; viết lại docstring tiếng Việt và tinh chỉnh các biểu thức chính quy regex cho số điện thoại Việt Nam.
Gemini / Antigravity	Hỗ trợ gợi ý khung kịch bản kiểm thử Pytest bao phủ 3 nhóm test case: Luồng đúng, Biên và Sai.	Sinh viên trực tiếp thiết kế bộ dữ liệu giả lập trong `conftest.py` dựa trên dữ liệu thật của Mekong Mobile; chạy lệnh `pytest -q` và kiểm tra từng trường hợp biên.
Gemini / Antigravity	Hỗ trợ phát hiện nguyên nhân lỗi Foreign Key khi chạy pipeline lần hai và gợi ý dùng UPDATE thay cho INSERT OR REPLACE.	Sinh viên thực hiện kiểm chứng thực nghiệm bằng việc truy vấn số dòng trong SQLite sau 2 lần chạy liên tiếp; xác nhận số lượng bản ghi không hề bị nhân đôi (Idempotent đạt 100%).

5.3. Cam kết học thuật

> Tôi xin cam đoan toàn bộ mã nguồn, dữ liệu thực nghiệm và tài liệu báo cáo này do chính tôi thực hiện dưới sự định hướng của Giảng viên hướng dẫn. Các đoạn mã nguồn tham khảo đều được trích dẫn và giải trình minh bạch. Toàn bộ các kết quả số liệu trong báo cáo đều được đo đạc trực tiếp từ việc thực thi mã nguồn thực tế trên máy tính, không có bất kỳ sự ngụy tạo số liệu nào.

Sinh viên cam kết
(Đã ký)

Hồ Lê Trung Bảo