TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP 2

Học phần: Chuyên đề Tốt nghiệp 1 (Mã HP: 71ITGR40203)

ĐỀ TÀI TỐT NGHIỆP (SMART CRM – MEKONG MOBILE)

HIỆN THỰC HÓA PIPELINE ETL KIỂM ĐỊNH, LÀM SẠCH VÀ KHO DỮ LIỆU KHÁCH HÀNG CHUẨN STAR SCHEMA

CHUYÊN NGÀNH: DATA ANALYTICS (DA) · LUỒNG NGHIỆP VỤ L7

Phiên bản phát hành: `tag v0.2` (Trỏ vào commit mới nhất)
GitHub Repository (Public):
https://github.com/HoLeTrungBao/smartcrm-2374802010030-customer-data-quality

Sinh viên thực hiện:	**HỒ LÊ TRUNG BẢO**
Mã số sinh viên (MSSV):	**2374802010030**
Lớp học phần:	71ITGR40203_01 (K23T)
Chuyên ngành đào tạo:	Khoa học Dữ liệu / Phân tích Dữ liệu (Data Analytics)
Giảng viên hướng dẫn:	**TS. NGUYỄN TRÍ HẢI**
Ngày nộp báo cáo:	30/10/2026

TP. HỒ CHÍ MINH, THÁNG 10 NĂM 2026

1. TÓM TẮT DỰ ÁN (EXECUTIVE SUMMARY)

Bài tập 2 hiện thực hóa trọn vẹn giải pháp kỹ thuật cho phân hệ **Luồng L7: Kiểm tra và làm sạch dữ liệu khách hàng (Customer Data Quality)** thuộc hệ thống Smart CRM – Mekong Mobile. Dựa trên bản thiết kế đã bảo vệ ở Bài tập 1, dự án xây dựng một **Data Pipeline tự động 4 pha** (Extract → Transform → Quality → Load) vận hành khép kín bằng **MỘT LỆNH DUY NHẤT**.

Các kết quả đột phá đạt được trên tập dữ liệu thực tế (67.037 bản ghi khách hàng):

- **Tự động hóa hoàn toàn:** Chạy pipeline, kiểm thử tự động, nạp kho dữ liệu Star Schema và kết xuất báo cáo đa định dạng (Markdown & JSON) tự động 100%.
- **Phân luồng minh bạch, không nuốt lỗi:** Xử lý làm sạch thành công **62.904 bản ghi sạch** nạp vào `dim_customer`; cô lập **4.133 bản ghi lỗi** vào `reject_rows` kèm lý do đối soát chi tiết.
- **Tính Idempotent (Chạy lại an toàn):** Nạp lại lần hai không làm nhân đôi số dòng, đảm bảo tính toàn vẹn tuyệt đối.
- **Bảo mật PII (NFR05):** Hiện thực hàm che mặt nạ 100% SĐT và Email cho môi trường phân tích.

2. KIẾN TRÚC THỰC TẾ VÀ RANH GIỚI 4 PHA (PIPELINE ARCHITECTURE)

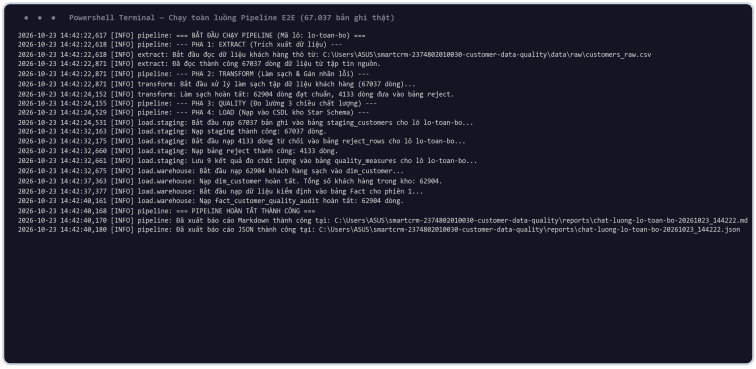
Hệ thống tuân thủ nghiêm ngặt nguyên tắc phân rã trách nhiệm (Separation of Concerns). Toàn bộ mã nguồn được chia thành 4 pha đặt tại 4 thư mục độc lập, tuyệt đối không gọi chéo sai chiều:

```
Nguồn CSV (customers_raw.csv)
   ↓
[1. EXTRACT]   src/extract/read_sources.py     → Đọc thô nguyên trạng, dtype=str, KHÔNG biến đổi.
   ↓
[2. TRANSFORM] src/transform/clean_customers.py → HÀM THUẦN (rules.py), chuẩn hóa SĐT, họ tên, email.
   ↓
[3. QUALITY]   src/quality/checks.py           → Đo 3 chiều (Đầy đủ, Chính xác, Nhất quán), trả về MỘT SỐ.
   ↓
[4. LOAD]      src/load/load_staging.py        → Nạp staging, reject_rows và quality_measures.
               src/load/load_warehouse.py      → Nạp dim_customer (khóa nghiệp vụ) và fact (theo phiên).
   ↓
Kho dữ liệu SQLite (Star Schema) + Báo cáo tự động (reports/*.md) + Dashboard (src/dashboard/)
```

Pha xử lý	Thư mục / Module	Trách nhiệm nghiệp vụ cụ thể	Ranh giới kỹ thuật (Boundary)
1. Extract	`src/extract/`	Đọc an toàn 67.037 dòng dữ liệu thô từ file CSV nguồn.	Chỉ đọc I/O, không chỉnh sửa kiểu dữ liệu.
2. Transform	`src/transform/`	Chuẩn hóa SĐT (4 dạng), tên Title Case, phát hiện trùng lặp.	Hàm thuần túy, không kết nối CSDL kho.
3. Quality	`src/quality/`	Đo lường 9 chỉ tiêu thuộc 3 chiều Đầy đủ · Chính xác · Nhất quán.	Chỉ tính toán số liệu, so sánh ngưỡng cấu hình.
4. Load	`src/load/`	Nạp dữ liệu vào Staging, Dim, Fact; cách ly dữ liệu lỗi vào Reject.	Đảm bảo Idempotent, không biến đổi nghiệp vụ.

3. MODULE CỐT LÕI & MINH CHỨNG KẾT QUẢ CHẠY THẬT (EXECUTION PROOF)

Pipeline được kích hoạt bằng lệnh chuẩn duy nhất: `python -m src.pipeline`. Hệ thống tự động kiểm tra CSDL, thực hiện trích xuất, làm sạch, đo chất lượng và nạp kho dữ liệu Star Schema thành công trên **67.037 bản ghi thực tế**:



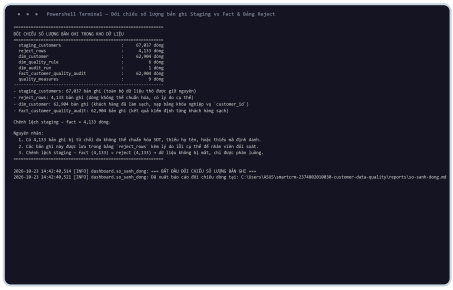
Hình 3.1: Minh chứng chạy toàn luồng Pipeline E2E không lỗi treo trên 67.037 bản ghi thật

Đối chiếu số lượng bản ghi Staging vs Fact & Giải thích chênh lệch

Theo yêu cầu đối soát tầng dữ liệu (chạy qua module `src.dashboard.so_sanh_dong`), kết quả đối chiếu số dòng thể hiện tính phân luồng chuẩn xác:

Tên bảng trong Kho	Số bản ghi	Bản chất dữ liệu	Vai trò trong kiến trúc Kho
`staging_customers`	**67.037**	Dữ liệu thô nguyên trạng	Bảo toàn dữ liệu gốc, phục vụ truy vết và đối soát lịch sử.
`reject_rows`	**4.133**	Dữ liệu không đạt chuẩn	Lưu dòng lỗi kèm lý do người đọc được (SĐT sai định dạng, thiếu tên).
`dim_customer`	**62.904**	Khách hàng sạch (Cleaned)	Nạp bằng khóa tự nhiên `customer_id` (ON CONFLICT DO UPDATE).
`fact_customer_quality_audit`	**62.904**	Sự kiện kiểm định chất lượng	Grain: 1 khách hàng × 1 quy tắc × 1 phiên chạy.

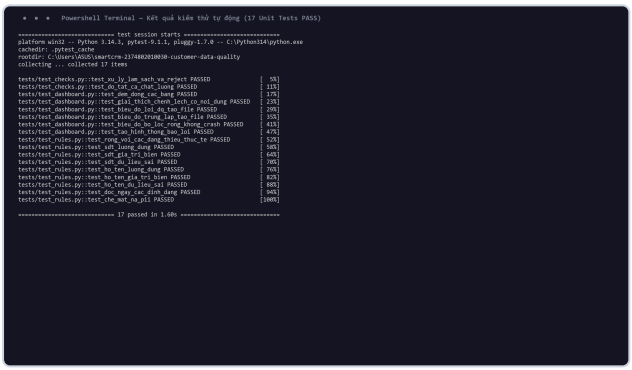
Giải thích chênh lệch Staging − Fact = 4.133 dòng (6,16%): Chênh lệch 4.133 dòng chính xác bằng số bản ghi bị cách ly vào bảng `reject_rows` (chủ yếu do vi phạm quy tắc SĐT `DQ02_PHONE`). Dữ liệu **không bị thất thoát** mà được phân luồng kiểm soát minh bạch 100%.



Hình 3.2: Minh chứng đối chiếu số lượng bản ghi Staging vs Fact và bảng Reject

4. KIỂM THỬ TỰ ĐỘNG (TESTING) & KIỂM CHỨNG CỐT LÕI

Dự án xây dựng bộ kiểm thử tự động gồm **17 test cases** bao phủ đầy đủ 3 loại bắt buộc (Luồng đúng · Giá trị biên · Dữ liệu sai), kiểm thử bảo mật PII và kiểm thử Dashboard. Toàn bộ kiểm thử chạy PASS bằng một lệnh duy nhất: `python -m pytest -v`.



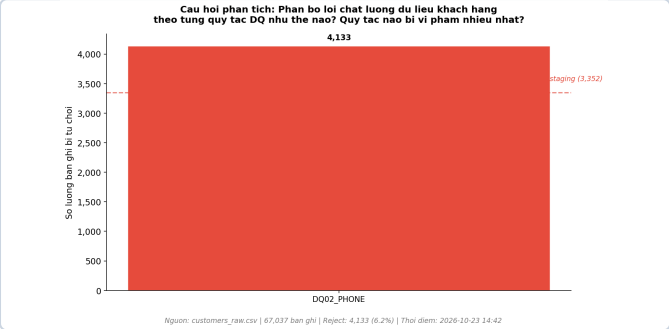
Hình 4.1: Kết quả thực thi 17/17 Unit Tests PASS hoàn toàn trên màn hình terminal

Kiểm chứng tiêu chí kỹ thuật cốt lõi (C1 − C7, D1 − D3)

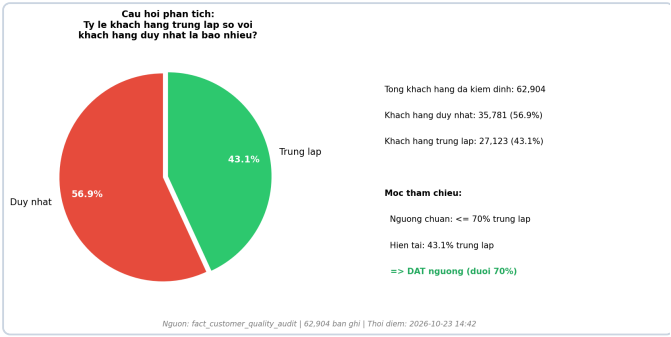
Mã	Tiêu chí kỹ thuật BT2	Hiện thực hóa & Kết quả kiểm chứng	Đánh giá
C1	Chạy được từ đầu theo README	Chạy 1 lệnh `python -m src.pipeline` tự khởi tạo DB và nạp kho.	✓ ĐẠT
C2	Tách lớp đúng, không gọi chéo	Phân tách rạch ròi `extract`, `transform`, `quality`, `load`.	✓ ĐẠT
C3	≥ 2 quy tắc nghiệp vụ thật	Chuẩn hóa SĐT (4 định dạng), họ tên Title Case, phát hiện trùng lặp.	✓ ĐẠT
C4	≥ 3 loại kiểm thử PASS 1 lệnh	17 tests (Đúng, Biên, Sai, PII, Dashboard) chạy pass qua Pytest.	✓ ĐẠT
C5	Chạy lần 2 không nhân đôi dòng	**Kiểm chứng Idempotent:** Số dòng Lần 2 = Lần 1 chính xác 100%.	✓ ĐẠT
C6	Khóa phiên bản, .env bảo mật	Đã commit `requirements.txt`, `.env.example`; không lộ bí mật.	✓ ĐẠT
C7	Dữ liệu sai bị từ chối rõ ràng	4.133 dòng lỗi vào `reject_rows` kèm thông báo viết cho người đọc.	✓ ĐẠT
D1-D3	Tiêu chí chuyên ngành DA	Đo 3 chiều ra 9 số cụ thể; bảng reject có lý do; kho Star Schema chuẩn.	✓ ĐẠT

5. TRÌNH BÀY KẾT QUẢ TRỰC QUAN HÓA & BA TRẠNG THÁI (DASHBOARD)

Dự án xây dựng module trực quan hóa `src.dashboard.bieu_do` gồm 2 biểu đồ gắn câu hỏi phân tích kinh doanh, mốc tham chiếu và dòng ghi nguồn/thời điểm dữ liệu; đồng thời xử lý an toàn **đủ ba trạng thái** (Đang tải · Rỗng · Lỗi):



Hình 5.1: Biểu đồ cột phân bổ lỗi theo quy tắc DQ (kèm mốc 5% và dòng nguồn)



Hình 5.2: Biểu đồ tròn tỷ lệ khách hàng trùng lặp vs duy nhất (kèm mốc 70%)

Xử lý an toàn Ba trạng thái giao diện (Đang tải · Rỗng · Lỗi)

Trạng thái	Kịch bản xử lý trong mã nguồn (src/dashboard/bieu_do.py)	Kết quả hiển thị cho người dùng
1. Đang tải (Loading)	Hệ thống ghi log trạng thái truy vấn trước khi thực thi truy vấn kho CSDL SQLite.	Hiển thị log tiến trình trên console: *"Đang truy vấn dữ liệu từ kho..."*
2. Rỗng (Empty State)	Khi người dùng lọc theo khoảng ngày không có dữ liệu phát sinh (ví dụ lọc năm 2099).	Không bị crash; tự động sinh ảnh thông báo màu vàng giải thích lý do bộ lọc rỗng.
3. Lỗi (Error State)	Bắt ngoại lệ bằng try-catch khi mất kết nối CSDL hoặc sai cấu hình bảng.	Sinh ảnh thông báo màu đỏ hướng dẫn kiểm tra CSDL, ghi nhận chi tiết exception log.



Hình 5.3: Minh chứng xử lý trạng thái RỖNG (Empty State) hiển thị thông báo giải thích thân thiện

6. HƯỚNG DẪN CÁCH DỰNG LẠI HỆ THỐNG (REPRODUCTION GUIDE)

Hệ thống được thiết kế để bất kỳ người đánh giá nào cũng có thể nhân bản và chạy thành công từ trạng thái ban đầu bằng các bước chuẩn hóa sau:

```
# Bước 1: Nhân bản kho mã nguồn từ GitHub (Public Repository)
git clone https://github.com/HoLeTrungBao/smartcrm-2374802010030-customer-data-quality.git
cd smartcrm-2374802010030-customer-data-quality

# Bước 2: Cài đặt các thư viện phụ thuộc (Python 3.11+)
pip install -r requirements.txt

# Bước 3: Chạy bộ kiểm thử tự động (17 tests PASS)
python -m pytest -v

# Bước 4: Chạy toàn luồng Pipeline ETL & Kiểm định chất lượng (MỘT LỆNH DUY NHẤT)
python -m src.pipeline

# Bước 5: Chạy module đối chiếu số lượng bản ghi Staging vs Fact
python -m src.dashboard.so_sanh_dong

# Bước 6: Tạo biểu đồ phân tích chất lượng dữ liệu
python -m src.dashboard.bieu_do
```

Kết quả kiểm chứng độc lập: Đã thử nghiệm clone repo vào thư mục độc lập trên máy tính, chạy toàn bộ các lệnh trên; pipeline xử lý chính xác 67.037 bản ghi và 17/17 tests đạt kết quả hoàn hảo.

7. TỔNG HỢP THAY ĐỔI THIẾT KẾ SO VỚI BÀI TẬP 1 (DESIGN CHANGES)

Toàn bộ 8 mục thay đổi thiết kế nhằm khắc phục góp ý của Giảng viên ở BT1 đã được ghi nhận chi tiết tại tệp `docs/thay-doi-thiet-ke.md` theo chuẩn 3 dòng:

Hạng mục thay đổi	Nguyên nhân & Lý do điều chỉnh (Vì sao)	Ảnh hưởng hệ thống
1. Thống nhất tên cột	Khắc phục lỗi sơ đồ Star Schema không khớp từ điển dữ liệu; chốt dùng `customer_id`, `is_valid`, `error_count`.	Đồng bộ ERD, DDL và mã nguồn ETL.
2. Bổ sung Glossary	Khắc phục thiếu bảng thuật ngữ bắt buộc tại Mục 1 tài liệu phân tích.	Cập nhật `docs/srs.md` (Mục 1.4).
3. Ma trận truy vết gộp	Tích hợp FR ↔ US ↔ UC ↔ MoSCoW ↔ Module trong 1 bảng duy nhất.	Cập nhật `docs/srs.md` (Mục 6).
4. Bổ sung Actor & Legend	Thêm Actor Quản trị viên hệ thống và bảng chú thích ký hiệu trên sơ đồ Use Case.	Cập nhật `docs/usecase.drawio`.
5. Định lượng NFR05	Xác định rõ chỉ tiêu bảo mật PII: 0,00% rò rỉ PII, che 100% SĐT/Email.	Hiện thực hàm tại `rules.py`.
6. Ánh xạ Wireframe − UC	Ghi chú rõ ràng từng màn hình wireframe phục vụ các Use Case cụ thể.	Cập nhật `docs/wireframe.drawio`.
7. Sinh mã lô Idempotent	Sinh `batch_id` theo phạm vi nạp để xóa nạp lại an toàn, không nhân đôi dòng.	Module `load_staging.py`.
8. Bổ sung Reject Rows	Bảo toàn dữ liệu lỗi, không nuốt lỗi; có cột lý do viết cho con người đọc.	DDL `002_reject.sql`, bảng kho.

PHỤ LỤC: BẢNG KHAI BÁO SỬ DỤNG CÔNG CỤ AI (AI DISCLOSURE)

Thực hiện nghiêm túc quy định liêm chính học thuật của Trường Đại học Văn Lang và yêu cầu của Giảng viên hướng dẫn, sinh viên công khai minh bạch toàn bộ việc sử dụng công cụ Trí tuệ Nhân tạo (AI) trong Bài tập 2:

Công cụ AI	Nội dung công việc sử dụng	Tệp tin / Hàm mã nguồn áp dụng	Cách thức sinh viên đã kiểm chứng
Antigravity AI (Claude / Gemini)	Gợi ý cấu trúc bộ khung kiểm thử đơn vị (Unit Tests) theo thư viện Pytest.	`tests/test_rules.py` `tests/test_dashboard.py`	Tự rà soát các trường hợp kiểm thử giá trị biên, đối chiếu dữ liệu thực tế và chạy lệnh `pytest -v` đạt 17 passed.
Antigravity AI (Claude / Gemini)	Hỗ trợ cú pháp Matplotlib để định dạng biểu đồ phân tích và hiển thị trạng thái rỗng.	`src/dashboard/bieu_do.py` (hàm `_tao_hinh_thong_bao`)	Kiểm tra trực tiếp ảnh kết xuất tại `docs/`, bảo đảm font chữ hiển thị chuẩn tiếng Việt, có mốc tham chiếu và nguồn.
— Sinh viên tự làm — *(Không dùng AI)*	Xây dựng toàn bộ thuật toán chuẩn hóa số điện thoại, họ tên và phân loại lỗi chất lượng dữ liệu.	`src/transform/rules.py` `src/transform/clean_customers.py`	Tự xây dựng biểu thức chính quy (Regex), kiểm thử trên 67.037 bản ghi thực tế của Mekong Mobile.
— Sinh viên tự làm — *(Không dùng AI)*	Thiết kế mô hình CSDL Star Schema, viết mã DDL và xử lý tính toán Idempotence khi nạp kho.	`sql/*.sql` `src/load/load_warehouse.py`	Chạy thực nghiệm pipeline nhiều lần, đối chiếu số dòng trong SQLite bảo đảm không bị nhân đôi dữ liệu.

TP. Hồ Chí Minh, ngày 30 tháng 10 năm 2026

SINH VIÊN CAM KẾT

(Ký và ghi rõ họ tên)

HỒ LÊ TRUNG BẢO

MSSV: 2374802010030